Artículo científico

Detección de voces clonadas por inteligencia artificial mediante Teachable Machine

Detection of AI-cloned voices using Teachable Machine

Detecção de vozes clonadas por inteligência artificial com Teachable Machine

Luis Marcelo Aguilera Salazar
Facultad de Ingeniería
Universidad Católica Boliviana San Pablo, Santa Cruz, Bolivia
https://orcid.org/0009-0000-9612-1998
luis.aguilera@ucb.edu.bo

Recibido: 17-10-2026

Resumen

El objetivo de la investigación fue desarrollar y evaluar un prototipo capaz de distinguir voces humanas reales de voces clonadas por inteligencia artificial, ante el uso creciente de la clonación de voz en el fraude telefónico. Se aplicó un enfoque cuantitativo con diseño experimental: seis participantes leyeron las mismas 20 frases en español, sus voces fueron clonadas con XTTS-v2 y con estos audios se entrenó en Teachable Machine un clasificador de aprendizaje automático de tres clases (ruido de fondo, voz real y voz clonada) basado en espectrogramas de un segundo. La evaluación se realizó con tres hablantes y cinco frases no vistos, en 276 fragmentos. Los resultados mostraron una exactitud de 64,1 %, una precisión de 55,2 %, una sensibilidad de 52,7 %, una especificidad de 71,7 % y un F1 de 0,540, superiores a los de un clasificador al azar. En conclusión, una herramienta de bajo costo y sin programación permite construir un primer filtro de detección de voces clonadas, cuyo desempeño depende de la variedad de voces usadas en el entrenamiento.

Palabras clave: inteligencia artificial, aprendizaje automático, voz, fraude.

Abstract

The objective of the research was to develop and evaluate a prototype capable of

distinguishing real human voices from voices cloned with artificial intelligence, given the growing use of voice cloning in phone fraud. A quantitative approach with an experimental design was applied: six participants read the same 20 sentences in Spanish, their voices were cloned with XTTS-v2, and these recordings were used to train a three-class machine learning classifier (background noise, real voice and cloned voice) in Teachable Machine, based on one-second spectrograms. The evaluation used three speakers and five sentences not seen in training, with 276 fragments. The results showed an accuracy of 64.1 %, a precision of 55.2 %, a recall of 52.7 %, a specificity of 71.7 % and an F1 score of 0.540, higher than those of a random classifier. In conclusion, a low-cost, no-code tool makes it possible to build a first filter for detecting cloned voices, whose performance depends on the variety of voices used in training.

Keywords: artificial intelligence, machine learning, voice, fraud.

Resumo

O objetivo da pesquisa foi desenvolver e avaliar um protótipo capaz de distinguir vozes humanas reais de vozes clonadas por inteligência artificial, diante do uso crescente da clonagem de voz em fraudes telefônicas. Aplicou-se uma abordagem quantitativa com delineamento experimental: seis participantes leram as mesmas 20 frases em espanhol, suas vozes foram clonadas com o XTTS-v2 e com esses áudios treinou-se no Teachable Machine um classificador de aprendizado de máquina de três classes (ruído de fundo, voz real e voz clonada) baseado em espectrogramas de um segundo. A avaliação foi feita com três falantes e cinco frases não vistos, em 276 fragmentos. Os resultados mostraram uma acurácia de 64,1 %, uma precisão de 55,2 %, uma sensibilidade de 52,7 %, uma especificidade de 71,7 % e um F1 de 0,540, superiores aos de um classificador aleatório. Em conclusão, uma ferramenta de baixo custo e sem programação permite construir um primeiro filtro de detecção de vozes clonadas, cujo desempenho depende da variedade de vozes usadas no treinamento.

Palavras-chave: inteligência artificial, aprendizado de máquina, voz, fraude.

Introducción

La síntesis de voz ha avanzado de forma acelerada en los últimos años. Los modelos de texto a voz de tipo *zero-shot*, como XTTS (Casanova et al., 2024) o F5-TTS (Chen et al., 2024), reproducen el timbre, el acento y la entonación de una persona a partir de pocos segundos de audio de referencia, sin reentrenar el modelo para cada hablante.

Esta capacidad facilita los *deepfakes* de audio: mensajes de voz en los que una persona estafadora imita a un familiar para pedir dinero, suplantación de autoridades de una empresa y ataques a la verificación biométrica por voz (Khanjani et al., 2023). Los desafíos ASVspoof publican bases de datos de habla sintetizada y reproducida para comparar defensas (Todisco et al., 2019; Wang et al., 2020; Liu et al., 2023).

Los primeros detectores usaron características acústicas clásicas, como los coeficientes cepstrales en escala Mel (Davis y Mermelstein, 1980), y los recientes emplean redes neuronales profundas, como AASIST (Jung et al., 2022). Sin embargo, pierden desempeño ante métodos de síntesis o grabaciones distintos a los del entrenamiento (Müller et al., 2022), lo que motivó bases de datos como WaveFake (Frank y Schönherr, 2021). Estos sistemas exigen programación avanzada y alta capacidad de cómputo. En cambio, Teachable Machine permite entrenar clasificadores de sonido sin escribir código (Carney et al., 2020), a partir de espectrogramas (Warden, 2018), y exporta los modelos a TensorFlow.js para ejecutarlos en el navegador (Smilkov et al., 2019). No se encontraron estudios que la evalúen para detectar voces clonadas en español.

En este contexto, el objetivo de la investigación fue desarrollar y evaluar un prototipo capaz de distinguir voces humanas reales de voces clonadas por inteligencia artificial mediante Teachable Machine, frente a hablantes y frases no vistos durante el entrenamiento. El manuscrito es resultado del proyecto de la asignatura de Inteligencia Artificial de la carrera de Ingeniería en Inteligencia Artificial, en el nivel de licenciatura, desarrollado durante el cuarto semestre.

Metodología

La investigación tuvo un enfoque cuantitativo con diseño experimental de tipo aplicado. La variable de respuesta fue la clase asignada por el modelo a cada fragmento de audio de un segundo (ruido de fondo, voz real o voz clonada), comparada con su clase verdadera. Participaron nueve personas voluntarias, elegidas por muestreo no probabilístico por conveniencia: seis aportaron las voces del entrenamiento y tres se reservaron para la prueba externa. Todas dieron su consentimiento para la grabación y la clonación de su voz con fines académicos.

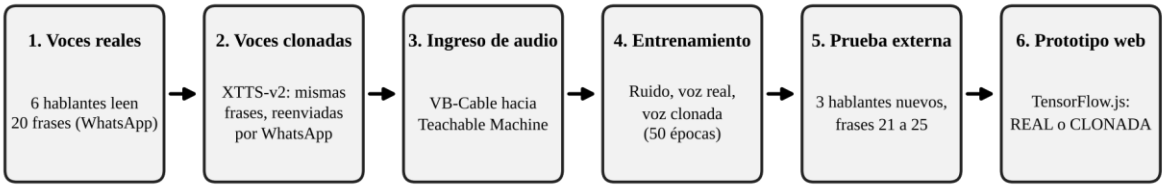
Se preparó un guion de 25 frases en español con contenido fonético variado. Las personas del entrenamiento leyeron las frases 1 a 20 (unos 90 segundos cada una) y las de la prueba solo las frases 21 a 25. Cada persona grabó con su propio teléfono celular y envió el audio por WhatsApp, por lo que el conjunto incluye distintos dispositivos y la compresión de esa aplicación.

Las voces clonadas se generaron con XTTS-v2 en una demostración pública de Hugging Face, con una referencia de 8 a 10 segundos de cada voz real, idioma español, temperatura de 0,85 y división nativa de oraciones. Se sintetizaron las mismas 20 frases en cinco bloques, con 30 audios de unos 14 segundos, que se reenviaron por WhatsApp para que ambas clases tuvieran la misma compresión. Al compartir hablantes, texto y formato, el modelo debió aprender rasgos de la síntesis y no la identidad ni el contenido.

El entrenamiento se hizo en un proyecto de audio de Teachable Machine. Los archivos se enviaron a la herramienta con el cable de audio virtual VB-Cable, sin ruido ambiental y por el mismo camino para ambas clases, y la herramienta los dividió en espectrogramas de un segundo. El ruido de fondo se grabó en cinco tomas de 20 segundos (silencio, ventilador, calle, teclado y música). El módulo solo permite ajustar las épocas, fijadas en 50, y reserva automáticamente una parte de las muestras para la validación interna. El modelo se exportó a TensorFlow.js y se integró en una página web que muestra la probabilidad de cada clase y alerta cuando la voz clonada supera el 80 %. La Figura 1 resume el flujo seguido.

Figura 1.

Flujo metodológico del prototipo de detección de voces clonadas



Nota. Elaboración propia.

Para la prueba externa se clonó con XTTS-v2 la voz de las tres personas reservadas con las frases 21 a 25, y se reenvió por WhatsApp. Los audios reales y clonados se reprodujeron con VB-Cable hacia la página web en modo de evaluación, que clasifica ventanas consecutivas de un segundo sin solapamiento, asigna la clase de mayor probabilidad y acumula la matriz de confusión; los silencios entre frases no se contabilizaron. El material se reprodujo en dos pasadas, porque la posición de las ventanas cambia en cada reproducción. Se calcularon la exactitud, la precisión, la sensibilidad, la especificidad, la exactitud balanceada y el F1, con la voz clonada como clase positiva.

Resultados y Discusión

La Tabla 1 muestra la composición del conjunto de datos. La voz real reúne 535 muestras de un segundo (51,8 %) del total de 1032, la voz clonada 397 (38,5 %) y el ruido de fondo 100 (9,7 %). La diferencia entre las dos clases de voz se debe a que los audios clonados tienen menos pausas que las grabaciones reales y producen menos segundos de habla para el mismo texto. En la prueba externa se clasificaron 276 ventanas de tres hablantes no vistos.

Tabla 1

Composición del conjunto de datos por clase

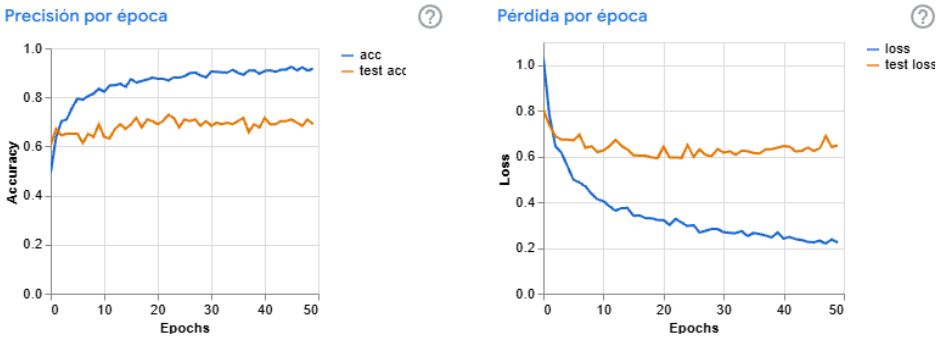
Clase	Hablantes	Audios fuente	Muestras de entrenamiento	Ventanas de prueba externa
Ruido de fondo	–	5 tomas de 20 s	100	No evaluada
Voz real	6	6 grabaciones	535	166
Voz clonada (XTTS-v2)	6	30 clones	397	110
Total	6	–	**1032**	**276**

Nota. Las ventanas de prueba suman las dos pasadas. Elaboración propia.

La Figura 2 muestra la exactitud y la pérdida por época. La exactitud de entrenamiento sube de 0,50 a cerca de 0,92, mientras que la de validación interna se estabiliza en torno a 0,70 desde la época 10; la pérdida de entrenamiento baja hasta cerca de 0,23 y la de validación se mantiene alrededor de 0,63. La brecha de unos 20 puntos entre ambas curvas indica sobreajuste: el modelo memoriza rasgos de las seis voces de entrenamiento, lo que anticipa el desempeño moderado ante hablantes nuevos.

Figura 2.

Exactitud y pérdida por época durante el entrenamiento



Nota. Gráficas generadas por Teachable Machine; acc y loss corresponden al entrenamiento, test acc y test loss a la validación interna. Elaboración propia.

Las métricas se calcularon con las ecuaciones [1] a [6], donde VP son las voces clonadas detectadas, VN las voces reales reconocidas como reales, FP las voces reales marcadas como clonadas y FN las voces clonadas aceptadas como reales. La exactitud balanceada no depende del número de ventanas de cada clase.

$$Exactitud = \frac{VP + VN}{VP + VN + FP + FN} \quad [1]$$

$$Precisión = \frac{VP}{VP + FP} \quad [2]$$

$$Sensibilidad = \frac{VP}{VP + FN} \quad [3]$$

$$Especificidad = \frac{VN}{VN + FP} \quad [4]$$

$$F1 = \frac{2 \times Precisión \times Sensibilidad}{Precisión + Sensibilidad} \quad [5]$$

$$Exactitud\ balanceada = \frac{Sensibilidad + Especificidad}{2} \quad [6]$$

La Tabla 2 presenta la matriz de confusión de la prueba externa. En conjunto, de las 166 ventanas de voz real el modelo clasifica 119 (71,7 %) como voz real y 47 (28,3 %) como clonada; de las 110 ventanas de voz clonada detecta 58 (52,7 %) y acepta 52 (47,3 %) como reales. La primera pasada supera a la segunda en ambas clases: reconoce 63 de 83 ventanas reales (75,9 %) frente a 56 (67,5 %) y detecta 31 de 56 clonadas (55,4 %) frente a 27 de 54 (50,0 %).

Tabla 2

Matriz de confusión de la prueba externa por pasada

Clase real	Pasada	Predicha: voz real	Predicha: voz clonada	Total
Voz real	1	63	20	83
Voz real	2	56	27	83
Voz real	Total	**119**	**47**	**166**
Voz clonada	1	25	31	56
Voz clonada	2	27	27	54
Voz clonada	Total	**52**	**58**	**110**

Nota. Ventanas de un segundo de tres hablantes no vistos; los silencios, clasificados como ruido de fondo, no se contabilizaron. Elaboración propia.

La Tabla 3 resume las métricas. Con ambas pasadas, el prototipo alcanza una exactitud de 64,1 % (177 de 276), una precisión de 55,2 % (58 de 105 alertas), una sensibilidad de 52,7 % (58 de 110) y un F1 de 0,540. La especificidad de 71,7 % supera a la sensibilidad, por lo que el modelo es más confiable al reconocer una voz real que al detectar una clonada. La diferencia de 7,0 puntos de exactitud entre pasadas, con el mismo material, muestra que el resultado varía según la posición de las ventanas sobre el audio.

Tabla 3

Métricas de desempeño en la prueba externa

Métrica	Pasada 1	Pasada 2	Ambas pasadas
Exactitud [1]	67,6 % (94/139)	60,6 % (83/137)	64,1 % (177/276)
Precisión [2]	60,8 % (31/51)	50,0 % (27/54)	55,2 % (58/105)
Sensibilidad [3]	55,4 % (31/56)	50,0 % (27/54)	52,7 % (58/110)
Especificidad [4]	75,9 % (63/83)	67,5 % (56/83)	71,7 % (119/166)
F1 [5]	0,579	0,500	0,540
Exactitud balanceada [6]	65,6 %	58,7 %	62,2 %

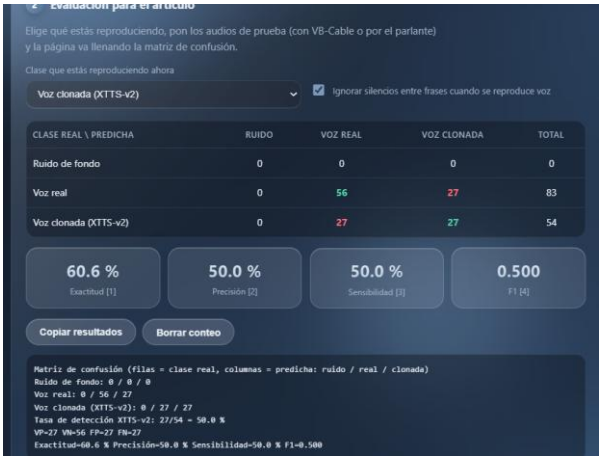
Nota. La clase positiva es la voz clonada. Elaboración propia.

Para valorar estos resultados se consideraron dos clasificadores de referencia que no aprenden del audio. Responder siempre voz real da una exactitud de 60,1 % (166 de 276) sin detectar ningún clon, y responder al azar da una exactitud balanceada de 50,0 % y un F1 esperado de 0,444. El prototipo supera a ambos: su exactitud balanceada de 62,2 % está 12,2 puntos por encima del azar y su F1 de 0,540 es 0,096 mayor, lo que confirma que aprende rasgos de la síntesis, con un margen moderado.

La Figura 3 muestra la página web del prototipo en modo de evaluación, con la matriz de confusión que se llena en tiempo real y las métricas principales. En modo de detección, el modelo se ejecuta en el navegador sin enviar el audio a ningún servidor.

Figura 3.

Página web del prototipo en modo de evaluación



Nota. Captura de la segunda pasada de la prueba externa. Elaboración propia.

Discusión

Los resultados muestran que una herramienta sin programación puede separar voces reales de voces clonadas por encima del azar cuando ambas clases comparten hablantes y contenido. Esto coincide con Khanjani et al. (2023), quienes describen que la síntesis deja huellas en el espectro que un clasificador puede aprovechar aunque el oído no las perciba.

El desempeño moderado ante hablantes no vistos es consistente con la falta de generalización reportada por Müller et al. (2022) para audios obtenidos fuera del laboratorio, y con los desafíos ASVspoof, donde la compresión y los canales de transmisión reducen la detección (Liu et al., 2023; Wang et al., 2020). El sobreajuste de la Figura 2 apunta en la misma dirección. Aquí todos los audios pasaron por WhatsApp, cuya compresión puede atenuar los artefactos de alta frecuencia, y el entrenamiento contó con solo seis voces.

Frente a sistemas especializados como AASIST (Jung et al., 2022), el prototipo usa un modelo pequeño con ventanas de un segundo y su desempeño absoluto es menor, pero se ejecuta en cualquier navegador gracias a TensorFlow.js (Smilkov et al., 2019). Entre las limitaciones están el número reducido de hablantes, un solo idioma, la evaluación de un único sistema de clonación, XTTS-v2, cuando WaveFake muestra la importancia de incluir varios métodos (Frank y Schönherr, 2021), y que el ruido de fondo no se evaluó en la prueba externa.

Conclusiones

El prototipo desarrollado con Teachable Machine distingue voces reales de voces clonadas por inteligencia artificial frente a hablantes y frases no vistos, con una exactitud de 64,1 %, una exactitud balanceada de 62,2 % y un F1 de 0,540, superiores a los de un clasificador al azar. Así, una herramienta de aprendizaje automático de bajo costo y sin programación sirve como primer filtro de detección.

El detector reconoce mejor las voces reales que las clonadas, con una especificidad de 71,7 % frente a una sensibilidad de 52,7 %, por lo que sus alertas son una señal de precaución y no una prueba definitiva. Su desempeño depende de la variedad de voces y sistemas de clonación del entrenamiento, y el mismo procedimiento puede escalarse

como una aplicación de verificación de llamadas y mensajes de voz.

Referencias

Carney, M., Webster, B., Alvarado, I., Phillips, K., Howell, N., Griffith, J., Jongejan, J., Pitaru, A., & Chen, A. (2020). Teachable Machine: Approachable web-based tool for exploring machine learning classification. En *Extended Abstracts of the 2020 CHI Conference on Human Factors in Computing Systems* (pp. 1–8). ACM. https://doi.org/10.1145/3334480.3382839

Casanova, E., Davis, K., Gölge, E., Göknar, G., Gulea, I., Hart, L., Aljafari, A., Meyer, J., Morais, R., Olayemi, S., & Weber, J. (2024). XTTS: A massively multilingual zero-shot text-to-speech model. *Interspeech 2024*. https://doi.org/10.48550/arXiv.2406.04904

Chen, Y., Niu, Z., Ma, Z., Deng, K., Wang, C., Zhao, J., Yu, K., & Chen, X. (2024). *F5-TTS: A fairytaler that fakes fluent and faithful speech with flow matching*. arXiv. https://doi.org/10.48550/arXiv.2410.06885

Davis, S., & Mermelstein, P. (1980). Comparison of parametric representations for monosyllabic word recognition in continuously spoken sentences. *IEEE Transactions on Acoustics, Speech, and Signal Processing, 28*(4), 357–366. https://doi.org/10.1109/TASSP.1980.1163420

Frank, J., & Schönherr, L. (2021). WaveFake: A data set to facilitate audio deepfake detection. *Proceedings of the Neural Information Processing Systems Track on Datasets and Benchmarks*. https://doi.org/10.48550/arXiv.2111.02813

Jung, J., Heo, H.-S., Tak, H., Shim, H., Chung, J. S., Lee, B.-J., Yu, H.-J., & Evans, N. (2022). AASIST: Audio anti-spoofing using integrated spectro-temporal graph attention networks. En *2022 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*. IEEE. https://doi.org/10.1109/ICASSP43922.2022.9747766

Khanjani, Z., Watson, G., & Janeja, V. P. (2023). Audio deepfakes: A survey. *Frontiers in Big Data, 5*, 1001063. https://doi.org/10.3389/fdata.2022.1001063

Liu, X., Wang, X., Sahidullah, M., Patino, J., Delgado, H., Kinnunen, T., Todisco, M., Yamagishi, J., Evans, N., Nautsch, A., & Lee, K. A. (2023). ASVspoof 2021:

Towards spoofed and deepfake speech detection in the wild. *IEEE/ACM Transactions on Audio, Speech, and Language Processing, 31*, 2507–2522. https://doi.org/10.1109/TASLP.2023.3285283

Müller, N., Czempin, P., Diekmann, F., Froghyar, A., & Böttinger, K. (2022). Does audio deepfake detection generalize? En *Proceedings of Interspeech 2022* (pp. 2783–2787). https://doi.org/10.21437/Interspeech.2022-108

Smilkov, D., Thorat, N., Assogba, Y., Yuan, A., Kreeger, N., Yu, P., Zhang, K., Cai, S., Nielsen, E., Soergel, D., Bileschi, S., Terry, M., Nicholson, C., Gupta, S. N., Sirajuddin, S., Sculley, D., Monga, R., Corrado, G., Viégas, F. B., & Wattenberg, M. (2019). TensorFlow.js: Machine learning for the web and beyond. *Proceedings of Machine Learning and Systems, 1*, 309–321. https://doi.org/10.48550/arXiv.1901.05350

Todisco, M., Wang, X., Vestman, V., Sahidullah, M., Delgado, H., Nautsch, A., Yamagishi, J., Evans, N., Kinnunen, T., & Lee, K. A. (2019). ASVspoof 2019: Future horizons in spoofed and fake audio detection. En *Proceedings of Interspeech 2019* (pp. 1008–1012). https://doi.org/10.21437/Interspeech.2019-2249

Wang, X., Yamagishi, J., Todisco, M., Delgado, H., Nautsch, A., Evans, N., Sahidullah, M., Vestman, V., Kinnunen, T., Lee, K. A., Juvela, L., Alku, P., Peng, Y.-H., Hwang, H.-T., Tsao, Y., Wang, H.-M., Le Maguer, S., Becker, M., Henderson, F., . . . Ling, Z.-H. (2020). ASVspoof 2019: A large-scale public database of synthesized, converted and replayed speech. *Computer Speech & Language, 64*, 101114. https://doi.org/10.1016/j.csl.2020.101114

Warden, P. (2018). *Speech commands: A dataset for limited-vocabulary speech recognition*. arXiv. https://doi.org/10.48550/arXiv.1804.03209

Sobre el autor

Luis Marcelo Aguilera Salazar es estudiante de cuarto semestre de la carrera de Ingeniería en Inteligencia Artificial de la Facultad de Ingeniería de la Universidad Católica Boliviana San Pablo, sede Santa Cruz, Bolivia. Sus intereses de investigación incluyen el aprendizaje automático, el procesamiento de audio y la seguridad frente a

contenidos generados por inteligencia artificial.

Financiamiento de la investigación

Con recursos propios.

Declaración de intereses

El autor declara no tener ningún conflicto de intereses que pueda haber influido en los resultados obtenidos o en las interpretaciones propuestas.

Declaración de consentimiento informado

El estudio se realizó respetando el Código de ética y buenas prácticas editoriales de publicación. Las nueve personas participantes dieron su consentimiento para la grabación y la clonación de su voz con fines académicos; sus nombres no se publican y los clones no se difundieron.